進捗報告

1 今週取り組んでいること

研究会で指摘を受けた Transformer Encoder に入力する CLS トークンの位置情報を付与する場合での実験をした.

2 データセット

データセットは楽天グループ株式会社が公開している「楽天トラベルレビュー: アスペクトセンチメントタグ付き コーパス」 *1 を使用した。楽天トラベルの日本語レビュー文章とそれぞれの文章について、立地、部屋、食事等の 7 項目の カテゴリに対するポジティブまたはネガティブのタグが付与されている。「朝食、夕食、風呂、サービス、施設、立地、部屋」 のポジティブ、ネガティブの 14 個のカテゴリに分類される。 今回は 14 のいずれのカテゴリにも属さないデータを除く ことで、少なくとも 1 つのラベルに属し、語彙数が 10 以下と 100 以上のデータを取り除いた。総データ数は 50211 である。

3 実験

14 個の CLS に位置情報を付与してマルチラベル分類をした. 図 1 にこれまでの提案モデル (Mpm+T) における CLS トークンの位置の指定について示す. 図 2 に本実験で用いた位置情報を付与する場合のトークンについて示す.

	Query	,			entity CLS 4	entity CLS 5	, ,	entity CLS 7	
--	-------	---	--	--	-----------------	-----------------	-----	-----------------	--

K	(ey	attribute						
		CLS 1	CLS 2	CLS 3	CLS 4	CLS 5	CLS 6	CLS 7
V	/alue							

図 1: 提案モデルでの CLS トークンの位置指定

Query	entity CLS 1	attribute CLS 1	entity CLS 2	entity CLS 6	attribute CLS 6	entity CLS 7	attribute CLS 7
Key	+	+	+	 +	+	+	+
Value	PE	PE	PE	PE	PE	PE	PE

図 2: 位置情報を付与する場合の CLS トークンの位置指定

表 1 に実験時のパラメータを示す.

表 2 に 5 分割交差検証をした各評価指標の平均と分散を示す. 比較対象として, 研究会で紹介した 3 つの場合の手法の結果も示している.

表 3 にテストデータにおける完全正解数や部分的正解数の詳細を示す。表 2 と同様に比較対象として、研究会で紹介した 3 つの場合の手法の結果も示している。

 $^{^{*1}\ \}mathrm{https://www.nii.ac.jp/dsc/idr/rakuten/}$

表 1: Mpm+T (cls に位置情報を付与) でのマルチラベル分類パラメータ

パラメータ	值
BERT の入力次元数	768
BERT の出力次元数	768
Transformer Encoder の入力次元数	768
Transformer Encoder の出力次元数	14
Transformer Encoder の層数	3
バッチサイズ	4
最適化関数	Adam
学習率	0.0000002
損失関数	BinaryCrossEntropyLoss
エポック数	15

表 2: 実験結果の評価指標の平均と標準偏差

評価指標	Precision	Recall	micro-F1	
Mpm+T (cls に位置情報を付与)	0.846 ± 0.019	0.872 ± 0.028	0.858 ± 0.017	
Mpm+T	0.848 ± 0.015	0.866 ± 0.013	0.851 ± 0.003	
BERT+MLP	0.683 ± 0.005	0.772 ± 0.009	0.724 ± 0.005	
三浦らのモデル	0.741 ± 0.015	0.804 ± 0.006	0.773 ± 0.013	

表 3: テストデータの完全 / 部分的正解数とマルチ / シングルラベルの完全正解率

評価指標	完全正解数	部分的正解数	マルチラベルの完全正解数	シングルラベルの完全正解数
Mpm+T (cls に位置情報を付与)	4311	1689	1298	3013
Mpm+T	4228	1772	1288	2940
BERT+MLP	3188	2812	862	2326
三浦らのモデル	3884	2116	1097	2787

表 2, 3 からは、Transformer Encoder に入力する CLS トークンの位置を固定する場合よりも、位置情報を付与する場合の方が分類精度が高いことがわかる。特にシングルラベルの完全正解数が向上していることがわかる。