

アンサンブル学習を利用した深層言語モデルによる マルチラベル分類手法の改良

第 1 グループ 楠本 祐暉

1. はじめに

近年、日々大量のテキストデータが執筆されている。それらを有効に活用するために、さまざまなシーンでテキスト分類タスクの需要が高まっている。テキスト分類タスクとは、事前に定義されたカテゴリまたはラベルをテキストに割り当てる処理である。特にビジネスシーンにおいては、作業の省人化とデータの有効活用を目的として、各テキストを自動的にカテゴリに分類すること、その精度を向上させることは大きな課題となっている。テキスト分類では 1 つのテキストに 1 つのラベルのみを割り当てる場合もあるが、データを有効活用するためにはテキストには 2 つ以上のラベルを割り当てる必要がある。このようにテキストに複数のラベルを割り当てるタスクはマルチラベル分類 (Multi Label Classification, MLC) と呼ばれ、自然言語処理 (Natural Language Processing, NLP) の分野では感情分析におけるタスクとして注目を集めている。その中でもアスペクトベースセンチメント分析 (Aspect-Based Sentiment Analysis, ABSA)[1] は文書から様々な観点を抽出し、その観点到感情極性を付与する研究である。本研究の目的は NLP におけるテキスト分類問題における、MLC の分類精度を向上させることである。分類対象となるテキストデータはアスペクトベースで作成された日本語文章のカスタマーレビューであり、単一または複数のラベルが付与されている。ABSA における MLC の分類精度向上は大きな課題であり、多くの先行研究が存在する。それらの中でも三浦らのモデル[2] は英語の文章データに対して高い識別精度を示しているが、日本語の文章データに対する識別精度[3] には改善の余地がある。そこで本研究では三浦らのモデルにアンサンブル学習を導入することで MLC の改良手法の有効性を検証をした。

2. データセット

2.1. 楽天トラベルレビュー: アスペクト・センチメントタグ付きコーパス

楽天グループ株式会社が事業等を通じて取得したデータから構築した「楽天データセット (コレクション)」[4] に含まれている「楽天トラベルレビュー: アスペクト・センチメントタグ付きコーパス」[5] を使用した。楽天トラベルの日本語レビュー文章とそれぞれの文章について、「朝食、夕食、風呂、サービス、施設、立地、部屋」の 7 項目の観点に対して、感情極性としてポジティブまたはネガティブのタグが付与されている。全てのデータに付与されるクラス数は 14 となり、該当するクラスには 1 が、該当しないクラスには 0 が付与されている。アスペクトはエンティティ (属性) とアトリビュート (属性) で構成される。全 76623 件のデータから、ノイズを含むデータや日本語以外の言語で書かれたデータと、文章のトークン数が 101 以上のデータを除外して、データ数は 73461 件となった。この処理後のデータセットから更に 2 種類のデータを除外した。それら 2 種類のデータは 14 のいずれのアスペクトにも属さないニュートラルデータ 23428 件と、1 つのアスペクトにポジティブとネガティブの両方が付与されたポジネガ両ラベルデータ 1858 件である。最終的にモデルの学習や評価に使用するデータ数は 48353 件となった。14 クラスのうち、ラベル 1 が 1 つしか付与されていないデータの数は 31731 件で、これをシングルラベルデータとする。また、14 クラスのうち、ラベル 1 が 2 つ以上付与されているデータの数は 16622 件で、これをマルチラベルデータとする。

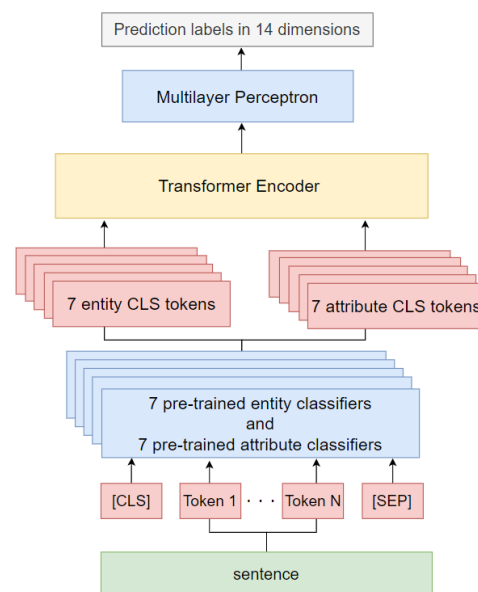


図 1: 提案モデル Multi pre-trained models Transformer (Mpm+T) の概要図

3. 提案手法

3.1. Entity Classifiers と Attribute Classifiers

MLC タスクにおいて 1 つの文章から複数のラベル分類情報を持つ特徴量を抽出することは容易ではない。そこで、ABSA におけるアスペクトに着目した。アスペクトは文章の書かれた対象と属性によって定義されることから、それぞれの対象と属性の分類に特化した小分類器を作成することとした。Entity Classifiers は「朝食、夕食、風呂、サービス、施設、立地、部屋」のアスペクトごとに作成した 7 個の 2 値分類器である。文書トークンを入力することで文書の分散表現を得る。Attribute Classifiers は「朝食、夕食、風呂、サービス、施設、立地、部屋」のアスペクトごとの感情極性としてポジティブまたはネガティブ (ポジネガ) を分類する 7 個の 2 値分類器である。Entity Classifiers と同様に文書トークンを入力することで文書の分散表現を得る。

3.2. Multi pre-trained models Transformer (Mpm+T)

本研究では、マルチラベル分類手法を改良するためにアンサンブル学習を利用した深層言語モデルである、Multi pre-trained models Transformer (Mpm+T) モデルを提案する。図 1 に本研究で作成した Mpm+T のモデル概要図を示す。モデルにおける CLS は BERT で使用されているタグの分散表現ベクトルである。まず、はじめに文書から文書トークンを生成する。次にそれらのトークンを小分類器である Entity Classifiers と Attribute Classifiers に入力してそれぞれから CLS トークンを得る。得られたそれぞれの CLS トークンに位置情報を付与して Transformer Encoder へ入力する。そしてマルチラベル分類情報を持った CLS トークンを抽出して、最後に Multi Layer Perceptron (MLP) に入力することで予測ラベルを得る。本提案モデルの全体的な構造と、BERT[6]

表 1: Entity classifiers と Attribute Classifiers の正解率の平均と標準偏差

	朝食	夕食	風呂	サービス	立地	施設	部屋
Entity Classifiers の正解率	0.916 \pm 0.002	0.923 \pm 0.006	0.943 \pm 0.006	0.888 \pm 0.005	0.951 \pm 0.001	0.868 \pm 0.01	0.919 \pm 0.001
Attribute Classifiers の正解率	0.936 \pm 0.001	0.922 \pm 0.005	0.917 \pm 0.001	0.926 \pm 0.001	0.925 \pm 0.003	0.908 \pm 0.094	0.905 \pm 0.007

表 2: 各 MLC モデルの評価指標の平均と標準偏差

Evaluation indices	Precision	Recall	micro-F1
Mpm+T	0.846 \pm 0.019	0.872 \pm 0.028	0.858 \pm 0.017
BERT+MLP	0.683 \pm 0.005	0.772 \pm 0.009	0.724 \pm 0.005
三浦らのモデル	0.741 \pm 0.015	0.804 \pm 0.006	0.773 \pm 0.013

表 3: 完全正解データを占めるマルチラベルデータとシングルラベルデータのデータ数と割合

データの種類	完全正解	
	マルチラベルデータ	シングルラベルデータ
Mpm+T	1298 (0.630)	3013 (0.764)
BERT+MLP	862 (0.418)	2326 (0.641)
三浦らのモデル	1097 (0.533)	2787 (0.706)

から得られる分散表現の内積計算機構として Transformer[7]を使用することは、先行研究 [2] である三浦らの提案モデルであるアスペクトベースセンチメント分析ネットワークに倣っている。本モデルと比較した場合の 2 つの新規な点を挙げる。1 点目は、各アスペクトの分類に特化した小分類器である Entity Classifiers と Attribute Classifiers をアンサンブル的に導入したことである。2 点目は、Transformer Encoder での計算量削減を目的として、小分類器から得られる分散表現のうち、CLS トークンのみを入力とすることである。

4. 数値実験

4.1. 実験 1

実験 1 では Mpm+T におけるアンサンブル学習のための小分類器である Entity Classifiers と Attribute Classifiers を作成した。Entity Classifiers はテキストのエンティティがあるアスペクトに該当するならラベル 1 を、そのアスペクトに該当しないならラベル 0 を付与する。Attribute Classifiers はテキストのアトリビュートを分析してポジティブまたはネガティブを 2 値分類する。ポジティブならラベル 1 を、ネガティブならラベル 0 を付与する。Entity Classifiers と Attribute Classifiers の識別性能を検証するために 5 分割交差検証をした。表 1 に Entity Classifiers と Attribute Classifiers の正解率の平均と標準偏差を示す。ほとんどのアスペクトにおいて小分類器は高い精度で 2 値分類ができていた。しかし、Entity Classifiers の「サービス」と「施設」の正解率は他のアスペクトに比べて低くなっている。これは Entity Classifiers の予測が 0 に寄ってしまう傾向があることと、「サービス」と「施設」のアスペクトにおける正例と負例の割合に起因する。各アスペクトに付与されている正例の割合の平均は 0.237 となっている一方で、サービスと施設はそれぞれ 0.372, 0.272 と平均を上回る割合である。そのため、予測が 0 に寄る傾向がある中で正例の多さが分類を難しくしたと考えられる。

4.2. 実験 2

実験 2 では Mpm+T の有効性の検証のため、30000 件のデータで、訓練データ 24000 件と検証データ 6000 件となるような 5 分割交差検証をした。比較手法として、2 種類を紹介する。従来手法の BERT+MLP と、三浦らのアスペクトベースセンチメント分析ネットワークの模倣モデルを選択した。それらの手法についても Mpm+T と同様のデータ数で 5 分割交差検証した。表 2 に検証データ 6000 件でのモデルの評価指標の平均と標準偏差を示す。関連研究 [2] と同様に

各モデルの micro-F1 を比較すると、Mpm+T は三浦らのモデルより 8.5% 向上した。ここで本研究の評価指標として、完全正解を定義する。完全正解とは、正解データと予測データの 14 個のラベルが全て一致した場合を指す。表 3 にテストデータ 6000 件において、各モデルの完全正解したマルチラベルデータとシングルラベルデータの数と割合を示す。Mpm+T の完全正解データ数はマルチラベルとシングルラベル共に比較手法を上回っていることが確認できる。特にマルチラベルデータの完全正解データ数の向上が著しく、データ数としては三浦らのモデルより 200 件多く正解している。このことから Mpm+T は比較手法よりも MLC に有効なモデルであるといえる。また、ABSA においてアンサンブル学習を導入することの有効性が確認できた。

5. まとめと今後の課題

本研究では、アンサンブル学習を利用した深層言語モデルによるマルチラベル分類の改良手法について述べた。先行研究と比較した新規性として、アスペクトに基づいた小分類器を導入することと、小分類器から得られる CLS トークンのみを Transformer Encoder の入力することが挙げられる。結果として、従来手法や先行研究の模倣モデルを上回る分類精度が確認できた。

今後の課題として、クレンジングで除いたデータなどを活用してモデルの汎用性を向上させることがある。また、それぞれの小分類器がアスペクト情報を抽出できていることを確認する必要がある。

参考文献

- [1] B. Liu. Sentiment analysis and opinion mining. *Synthesis lectures on human language technologies*, Vol. 5(No. 1):pp. 1-167, 2012.
- [2] 三浦義栄, 渥美雅保. 事前学習言語モデルを用いたアスペクトベースセンチメント分析ニューラルネットワーク. 人工知能学会全国大会論文集 第 35 回 (2021), pp. 2Yin507-2Yin507. 一般社団法人 人工知能学会, 2021.
- [3] 三浦義栄, 赤井龍一, 渥美雅保. 文中の複数アスペクトのセンチメント分析のための自己注意ニューラルネットワーク. 人工知能学会全国大会論文集 第 34 回 (2020), pp. 3Rin441-3Rin441. 一般社団法人 人工知能学会, 2020.
- [4] 楽天グループ株式会社. 楽天データセット (コレクション), Aug 2010.
- [5] 楽天グループ株式会社. 楽天トラベルレビュー: アスペクト・センチメントタグ付きコーパス, Feb 2021.
- [6] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2018.
- [7] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need. In *Advances in neural information processing systems*, pp. 5998-6008, 2017.